

รายงานวิชา 2603430 การวิเคราะห์อนุกรมเวลา (2567/1)

การทำนายราคากากั่วเหลืองในประเทศเนปาล

สมาชิก

- 1.นางสาวพิรญาณ์ ยิ่งพิศิษฐ์ เลขประจำตัวนิสิต 6542086026
- 2.นายประเมษฐ์ เขาวนธ์นสิทธิ์ เลขประจำตัวนิสิต 6542067026
- 3.นายจักรภัทร วีระวิทยานันต์ เลขประจำตัวนิสิต 6542016026
- 4.นางสาวชญาภรณ์ สวัสดิ์มงคล เลขประจำตัวนิสิต 6542022826
- 5.นายชนน วงษ์คนดี เลขประจำตัวนิสิต 6542023426

หลักสูตรสถิติศาสตร์บัณฑิต คณะพาณิชยศาสตร์และการบัญชี  
จุฬาลงกรณ์มหาวิทยาลัย

### บทคัดย่อ

การศึกษานี้มีวัตถุประสงค์เพื่อวิเคราะห์และพยากรณ์ราคาขึ้นตำรายวันของถั่วเหลือง Okara ในประเทศเนปาล โดยใช้ข้อมูลราคาขึ้นตำรายวันย้อนหลังตั้งแต่ปี 2013-2021 ซึ่งข้อมูลดังกล่าวมีความผันผวนตามฤดูกาล การวิเคราะห์ข้อมูลเบื้องต้นเผยให้เห็นรูปแบบความสัมพันธ์ของฤดูกาลและความนิ่งของข้อมูล โดยใช้เทคนิค Augmented Dickey-Fuller Test เพื่อยืนยันความนิ่งของข้อมูล สำหรับการพยากรณ์ข้อมูล ใช้โมเดล SARIMA, ETS และ GRU ในการเปรียบเทียบผลลัพธ์ พบว่าโมเดล GRU มีประสิทธิภาพสูงสุด โดยมีค่าความคลาดเคลื่อนเฉลี่ยต่ำที่สุด ( $MAE = 7.36$ ) และค่าความคลาดเคลื่อนรากที่สองต่ำสุด ( $RMSE = 10.51$ ) เมื่อเทียบกับโมเดลอื่น การศึกษานี้ชี้ให้เห็นว่า GRU เป็นทางเลือกที่เหมาะสมสำหรับการพยากรณ์ข้อมูลและสนับสนุนการตัดสินใจในอุตสาหกรรมการเกษตรของเนปาลในอนาคต

คำสำคัญ: การพยากรณ์ราคา, ถั่วเหลือง, ARIMA, Exponential Smoothing, Neural Network, ประเทศเนปาล, การเกษตร

## บทนำ

### ที่มาและความสำคัญของปัญหา

ในปัจจุบันความผันผวนของราคาสินค้าเกษตรกรรมโดยเฉพาะอย่างยิ่งถั่วเหลือง Okara ในประเทศเนปาลส่งผลกระทบต่อการตัดสินใจในอุตสาหกรรมการผลิตและการเกษตรอย่างหลีกเลี่ยงไม่ได้ เนื่องจาก Okara ถือเป็นหนึ่งในวัตถุดิบที่สำคัญสำหรับการผลิตโปรตีนจากพืชซึ่งเป็นที่ต้องการอย่างสูงในตลาดโลก การพยากรณ์ราคาถั่วเหลือง Okara จึงมีบทบาทสำคัญในเชิงเศรษฐกิจเพื่อช่วยสนับสนุนการวางแผนและบริหารจัดการในภาคอุตสาหกรรม และยังมีส่วนช่วยในการลดความเสี่ยงที่เกิดจากความไม่แน่นอนของราคาในตลาดปัญหาหลักที่พบคือข้อมูลราคาที่มีความแปรปรวนสูงและมีช่องว่างข้อมูลบางส่วน ทำให้การวิเคราะห์แนวโน้มและการพยากรณ์ราคามีข้อจำกัด งานวิจัยนี้จึงได้มุ่งเน้นการพัฒนาวิธีการปรับปรุงข้อมูลที่ขาดหาย (Imputation) การใช้โมเดลที่เหมาะสมสำหรับการพยากรณ์ และการเปรียบเทียบประสิทธิภาพของโมเดลเหล่านี้ เพื่อเพิ่มความถูกต้องและลดความเสี่ยงของข้อผิดพลาดในการพยากรณ์ราคา

### วัตถุประสงค์

1. เพื่อสร้างตัวแบบอนุกรมเวลาที่สามารถอธิบายราคาถั่วเหลือง Okara ในประเทศเนปาลอย่างมีประสิทธิภาพ
2. เพื่อเปรียบเทียบประสิทธิภาพของโมเดลการพยากรณ์ราคาถั่วเหลือง Okara ในช่วงเวลาต่าง ๆ และเลือกตัวแบบที่เหมาะสมที่สุด

## นิยามศัพท์เฉพาะ

**อนุกรมเวลา** หมายถึง ข้อมูลที่รวบรวมและจัดเก็บในลำดับของช่วงเวลาต่อเนื่องกัน เพื่อแสดงการเปลี่ยนแปลงของข้อมูลในแต่ละช่วง เช่น ราคาขั้นต่ำของถั่วเหลือง Okara รายเดือนในเนपाल ซึ่งถูกใช้ในการวิเคราะห์แนวโน้มและฤดูกาล

**Okara** หมายถึง ผลพลอยได้จากกระบวนการผลิตนมถั่วเหลืองหรือเต้าหู้ มีลักษณะเป็นของแข็งที่มีไฟเบอร์ โปรตีน และสารอาหารอื่น ๆ สูง ถูกนำมาใช้ในอุตสาหกรรมอาหาร เช่น การผลิตโปรตีนจากพืชหรือผลิตภัณฑ์แปรรูปอื่น ๆ

**ความผันผวนของราคา Okara** หมายถึง การเปลี่ยนแปลงของราคาขั้นต่ำของ Okara ในแต่ละช่วงเวลา ซึ่งอาจได้รับอิทธิพลจากปัจจัยภายนอก เช่น สภาพอากาศ ฤดูกาล และความต้องการในตลาด

**ฤดูกาลของราคา Okara** หมายถึง รูปแบบการเปลี่ยนแปลงของราคาขั้นต่ำของ Okara ที่แสดงลักษณะซ้ำ ๆ ตามช่วงเวลา เช่น ราคาลดลงในฤดูฝน (เดือนมิถุนายนถึงกันยายน) และราคาสูงขึ้นในฤดูหนาว (เดือนมกราคมถึงมีนาคม)

**แนวโน้มราคา Okara** หมายถึง ทิศทางการเปลี่ยนแปลงของราคาขั้นต่ำของ Okara ในระยะยาว ซึ่งอาจเป็นขาขึ้น ขาลง หรือคงที่ ขึ้นอยู่กับปัจจัยทางเศรษฐกิจและการเกษตร

## ขอบเขตการศึกษา

การศึกษานี้มีวัตถุประสงค์เพื่อสร้างตัวแบบที่สามารถพยากรณ์ราคาขั้นต่ำของถั่วเหลือง Okara ในประเทศเนपालได้อย่างมีประสิทธิภาพ โดยใช้ข้อมูลราคาขั้นต่ำรายวันจากปี ค.ศ. 2013 ถึง ค.ศ. 2021 จากแหล่งข้อมูลของ Federal Reserve Bank of St. Louis (FRED) การศึกษานี้จะมุ่งเน้นการเปรียบเทียบโมเดลที่หลากหลาย เช่น SARIMA, ETS และ GRU เพื่อวิเคราะห์ประสิทธิภาพและเลือกตัวแบบที่เหมาะสมที่สุด

## ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

ตัวแบบ SARIMA (Seasonal Autoregressive Integrated Moving Average) เป็นเครื่องมือสำคัญในการวิเคราะห์ข้อมูลอนุกรมเวลาที่มีลักษณะเป็นฤดูกาล โดย SARIMA ใช้การผสมผสานระหว่างองค์ประกอบเชิงสถิติ ได้แก่ การถดถอยอัตโนมัติ (Autoregressive: AR) การเคลื่อนที่เฉลี่ย (Moving Average: MA) การรวมความแตกต่าง (Integrated: I) และฤดูกาล (Seasonal) ซึ่งทำให้เหมาะสมสำหรับการพยากรณ์ข้อมูลที่มีแนวโน้ม ชับซ้อนและมีฤดูกาลชัดเจน

ตัวแบบ ETS (Error-Trend-Seasonality) เป็นเทคนิคการพยากรณ์ที่ให้ความสำคัญกับองค์ประกอบสามประการ ได้แก่ ความผิดพลาด (Error) แนวโน้ม (Trend) และฤดูกาล (Seasonality) โดย ETS เน้นการคำนวณข้อมูลที่ไม่มีแนวโน้มและฤดูกาลที่ซับซ้อนมากนัก เหมาะสำหรับข้อมูลที่มีรูปแบบคงที่หรือเปลี่ยนแปลงเล็กน้อยตามเวลา

ตัวแบบ GRU (Gated Recurrent Unit) เป็นโครงข่ายประสาทเทียมที่ถูกออกแบบมาเพื่อจัดการกับข้อมูลที่มีลักษณะเป็นลำดับต่อเนื่อง เช่น ข้อมูลอนุกรมเวลา GRU สามารถเรียนรู้ความสัมพันธ์ระยะยาวในข้อมูลได้ดี โดยใช้พารามิเตอร์ที่น้อยกว่า LSTM ทำให้เหมาะสมสำหรับข้อมูลที่มีข้อจำกัดด้านปริมาณหรือความซับซ้อน

Kalman Filter เป็นเทคนิคการเติมข้อมูลขาดหายที่ใช้สำหรับข้อมูลอนุกรมเวลา โดยมีจุดเด่นในการประมวลผลข้อมูลที่มีแนวโน้ม ฤดูกาล และสัญญาณรบกวน (Noise) ได้อย่างแม่นยำ เทคนิคนี้ช่วยเพิ่มความสำเร็จของข้อมูล ทำให้ผลการวิเคราะห์และพยากรณ์มีความน่าเชื่อถือมากขึ้น

## การจัดเตรียมข้อมูลและการแบ่งข้อมูล

จากข้อมูลราคาขึ้นตำรายวันของถั่วเหลือง Okara ในประเทศเนปาล ตั้งแต่ปี ค.ศ. 2013 ถึงปี ค.ศ. 2021 มีจำนวนทั้งหมด 2663 แถว พบว่าข้อมูลแสดงลักษณะตามฤดูกาล (Seasonality) อย่างชัดเจน แต่มีแนวโน้ม แนวโน้ม (Trend) ที่ไม่ชัดเจน โดยราคามักลดลงในช่วงฤดูฝน (เดือนมิถุนายนถึงกันยายน) และเพิ่มขึ้นในช่วงฤดูหนาว (เดือนมกราคมถึงมีนาคม) ซึ่งเป็นช่วงที่ถั่วเหลืองในเนปาลมีการเก็บเกี่ยวอย่างมีคุณภาพ นอกจากนี้ การวิเคราะห์ ACF และ PACF ยืนยันว่าข้อมูลมีความสัมพันธ์เชิงเวลาในหลายช่วง (lag) ซึ่งสะท้อนถึงรูปแบบที่เกิดขึ้นซ้ำตามฤดูกาล

## การจัดการข้อมูล

เราจะจัดการข้อมูลหลังจากที่ได้ทำการแยกชุดข้อมูลเป็น train กับ test dataset แล้ว เพื่อป้องกัน data leakage

**ข้อมูลขาดหาย (Missing Data)** ข้อมูลที่ใช้มีวันที่ขาดหายไปทั้งหมด 226 วัน ซึ่งอาจเกิดจากความไม่ต่อเนื่องในการเก็บข้อมูล โดยการเติมค่าข้อมูลที่ขาดหายนี้ได้ใช้วิธี Kalman Filter ซึ่งเป็นเทคนิคที่เหมาะสมสำหรับข้อมูลอนุกรมเวลาที่มีแนวโน้มและฤดูกาล

**ค่าผิดปกติ (Outliers)** ใช้ฟังก์ชัน tsoutliers() เพื่อตรวจสอบค่าผิดปกติ พบว่ามีค่าที่เบี่ยงเบนจากแนวโน้มปกติในบางช่วง เช่น ราคาที่ลดลงอย่างฉับพลันในฤดูฝน ค่าผิดปกติเหล่านี้ได้รับการแทนที่ด้วยค่าที่คำนวณจาก Kalman Filter เพื่อให้ข้อมูลสม่ำเสมอและลดผลกระทบต่อการวิเคราะห์

**การตรวจสอบความนิ่งของข้อมูล (Stationarity Check)** ใช้การทดสอบ Augmented Dickey-Fuller (ADF) Test เพื่อประเมินความนิ่งของข้อมูล พบว่า ค่า p-value < 0.05 แสดงว่าข้อมูลสามารถทำให้เป็นนิ่งได้ (Stationary)

**การแบ่งชุดข้อมูล (Data Splitting)** เพื่อเตรียมข้อมูลสำหรับการสร้างแบบจำลองและประเมินผล ได้แบ่งข้อมูลออกเป็น

- ชุดข้อมูลฝึก (Training Set): ใช้ข้อมูล 80% แรกของชุดข้อมูล (จากปี ค.ศ. 2013 ถึงประมาณปี ค.ศ. 2019)
- ชุดข้อมูลทดสอบ (Testing Set): ใช้ข้อมูล 20% ที่เหลือ (จากปี ค.ศ. 2019 ถึงปี ค.ศ. 2021)

**การแยกส่วนข้อมูล (Decomposition)** ใช้การแยกส่วนข้อมูลแบบ Additive Decomposition ด้วยฟังก์ชัน stl() เพื่อแยกองค์ประกอบของข้อมูลออกเป็นแนวโน้ม (Trend) ฤดูกาล (Seasonality) และส่วนที่เหลือ (Remainder) พบว่าข้อมูลมีรูปแบบฤดูกาลที่เกิดซ้ำทุก 365 วัน (1 ปี)

**การตรวจสอบความสัมพันธ์** การวิเคราะห์ความสัมพันธ์ด้วย ACF และ PACF แสดงให้เห็นว่าข้อมูลมีความสัมพันธ์อย่างมีนัยสำคัญที่ lag 1 ถึง 4 ซึ่งชี้ให้เห็นถึงความสำคัญของฤดูกาลและแนวโน้มที่ส่งผลต่อข้อมูล

กระบวนการจัดเตรียมข้อมูลและการแบ่งข้อมูลนี้ช่วยให้ได้ชุดข้อมูลที่สมบูรณ์และเหมาะสมสำหรับการสร้างแบบจำลองการพยากรณ์ เช่น SARIMA, ETS, หรือ GRU การวิเคราะห์ข้อมูลที่ละเอียดและการจัดการข้อมูลที่เหมาะสมนี้จะช่วยเพิ่มความแม่นยำในการพยากรณ์ราคาขั้นต่ำของถั่วเหลือง Okara และสนับสนุนการตัดสินใจในอุตสาหกรรมเกษตรของเนปาลได้อย่างมีประสิทธิภาพ

## ขั้นตอนการสร้างตัวแบบเพื่อการวิเคราะห์ข้อมูล

### 1. ตัวแบบ SARIMA

ขณะดำเนินการใช้ SARIMA เพื่อสร้างโมเดล ได้เกิดข้อผิดพลาด โดยมีสาเหตุมาจากการกำหนดค่า lag ที่เกินขีดจำกัดสูงสุดที่ระบบรองรับ ซึ่งกำหนดไว้ที่ 350

เพื่อแก้ไขปัญหาดังกล่าว วิธีการที่เหมาะสมคือการรวมข้อมูล (Aggregate) ให้มีความถี่ที่ต่ำลง เช่น การปรับข้อมูลให้อยู่ในระดับรายเดือน (Monthly) โดยใช้ราคาต่ำที่สุดของแต่ละเดือน ซึ่งช่วยลดความซับซ้อนของข้อมูลและทำให้สามารถนำไปใช้งานกับโมเดล ได้อย่างเหมาะสม

เมื่อทำการตรวจสอบคุณสมบัติความนิ่งด้วย ADF test พบว่า ค่า p-value น้อยกว่า 0.01 ซึ่งน้อยกว่า 0.05 จึงปฏิเสธ  $H_0$  นั่นคือ ข้อมูลอนุกรมเวลามีคุณสมบัติความนิ่ง และเมื่อทดสอบด้วย KPSS test พบว่า ค่า p-value มากกว่า 0.1 ซึ่งมากกว่า 0.05 จึงไม่สามารถปฏิเสธ  $H_0$  นั่นคือ ข้อมูลอนุกรมเวลามีคุณสมบัติความนิ่ง ดังนั้น จากผลการทดสอบทั้งสองจึงสรุปได้ว่า ข้อมูลอนุกรมเวลามีคุณสมบัติความนิ่ง

แต่เมื่อวิเคราะห์กราฟ ACF และ PACF กลับพบว่าข้อมูล ยังคงมีแนวโน้ม(trend)เป็นองค์ประกอบอยู่ จึงได้นำข้อมูลอนุกรมเวลามาทำการ differencing 1 ครั้ง และเมื่อวิเคราะห์กราฟพบว่าข้อมูลมีความนิ่งแล้ว

จากนั้นจึงเริ่มต้นพิจารณา PACF plot พบว่าที่ lag ค่า partial autocorrelation มีค่าไม่แตกต่างจาก 0 อย่างมีนัยสำคัญที่ระดับความเชื่อมั่น 95% จึงสรุปได้ว่า p order = 3 และ P order = 0

จากนั้นจึงเริ่มต้นพิจารณา ACF plot พบว่าที่ lag ค่า autocorrelation มีค่าไม่แตกต่างจาก 0 อย่างมีนัยสำคัญที่ระดับความเชื่อมั่น 95% จึงสรุปได้ว่า q order = 3 และ Q order = 3

จากการวิเคราะห์ทั้งหมด จึงได้ว่า ค่า(p,d,q) และ (P, D, Q) เป็น SARIMA(3, 1, 3)×(0, 0, 3)<sub>12</sub>

เมื่อทำการทดสอบ short-term correlation ของ residual ด้วย Ljung-Box test พบว่า ค่า p-value เท่ากับ 0.8394 ซึ่งมากกว่าค่า alpha ที่ 0.05 หมายความว่าไม่มี short-term correlation ของ residual บ่งชี้ว่าแบบจำลองมีแนวโน้มที่จะ fit ข้อมูลได้ดีในแง่ของการอธิบายโครงสร้างเชิงเวลา (time dependency) ของข้อมูล

ต่อมาทำการวิเคราะห์ normality ด้วย histogram พบว่า มีลักษณะเป็นรูประฆังคว่ำ จึงสามารถสรุปได้ว่า residual ส่วนที่เหลือจากการใช้ตัวแบบ SARIMA มาอธิบายข้อมูลนั้น มีการแจกแจงแบบปกติ และเมื่อทำการสร้าง ACF plot ของค่า residual พบว่าที่ lag 1 ค่า autocorrelation มีค่าไม่แตกต่างจาก 0 อย่างมีนัยสำคัญที่ระดับความเชื่อมั่น 95%

จากการทดสอบ residual ทั้งหมดพบว่า residual นั้นเป็น purely random process แล้ว จึงสามารถสรุปได้ว่าตัวแบบ SARIMA(3, 1, 3)x(0, 0, 3)<sub>12</sub> เป็นตัวแบบที่มีประสิทธิภาพ เหมาะสำหรับการใช้ทำนายราคาในอนาคต และนำมาเปรียบเทียบกับประสิทธิภาพของตัวแบบ

ตารางที่ 1 แสดงค่า MAE, RMSE และ MAPE ของตัวแบบ SARIMA(3, 1, 3)x(0, 0, 3)<sub>12</sub>

Model	MAE	RMSE	MAPE
SARIMA	11.34787	14.82118	39.39234%

## 2. ตัวแบบ Exponential Smoothing

จากผลการทดสอบด้วย ADF และ KPSS สามารถสรุปได้ว่าข้อมูลราคารายเดือนมีความนิ่ง (Stationary) ซึ่งบ่งชี้ว่าไม่มีแนวโน้ม (Trend) นอกจากนี้ จากการสังเกตกราฟ deompose รายเดือน พบว่าการเปลี่ยนแปลงของข้อมูลตามฤดูกาลมีลักษณะคงที่และสม่ำเสมอในทุกช่วงเวลา จึงเลือกทดสอบ ETS ทั้งหมด 3 โมเดล ได้แก่ ETS(M, N, M), ETS(M, N, A) และ ETS(A, N, A)

ตารางที่ 2 แสดงค่า AIC, BIC และ AICc เปรียบเทียบกันทั้ง 3 โมเดล

Model	AIC	BIC	AICc
ETS(M, N, M)	692.3304	727.4875	700.1992
ETS(M, N, A)	687.4437	722.6008	695.3126
ETS(A, N, A)	686.6299	721.7870	694.4987

จากตารางจะได้ว่าค่า AIC, BIC และ AICc ที่ต่ำที่สุดคือโมเดล ETS(A, N, A)

เมื่อทำการทดสอบ short term correlation ของ residual ในโมเดล ETS(A, N, A) ด้วย Ljung-Box test พบว่า ค่า p-value เท่ากับ 0.2922



ต่อมาทำการวิเคราะห์ normality ด้วยกราฟ histogram พบว่า มีลักษณะเป็นรูประฆังคว่ำ จึงสามารถสรุปได้ว่า residual ส่วนที่เหลือจากการใช้ตัวแบบ ETS(A, N, A) มาอธิบายข้อมูลนั้น มีการแจกแจงแบบปกติ และเมื่อทำการสร้าง ACF plot ของค่า residual พบว่าที่ lag 1 ค่า autocorrelation มีค่าไม่แตกต่างจาก 0 อย่างมีนัยสำคัญที่ระดับความเชื่อมั่น 95%

จากการทดสอบ residual ด้วย Ljung-Box test พบว่า residual นั้นเป็น purely random process แล้ว จึงสามารถสรุปได้ว่าตัวแบบ ETS(A, N, A) เป็นตัวแบบที่มีประสิทธิภาพ เหมาะสำหรับการใช้ทำนายราคาในอนาคต และนำมาเปรียบเทียบกับประสิทธิภาพของตัวแบบ

ตารางที่ 3 แสดงค่า MAE, RMSE และ MAPE ของตัวแบบ ETS(A, N, A)

Model	MAE	RMSE	MAPE
ETS(A, N, A)	10.4866	12.48023	29.2627%

### 3.ตัวแบบ GRU(Gated Recurrent Unit)

ข้อมูลที่ใช้ประกอบด้วย เดือนและ ปี เป็นฟีเจอร์หลัก และ ราคาต่ำสุด เป็นค่าที่ต้องการทำนาย โดยมีการสร้างชุดข้อมูลลำดับเวลา (time\_steps = 12) และปรับข้อมูลให้อยู่ในช่วง [0, 1] ด้วย MinMaxScaler

โมเดล GRU มีโครงสร้างดังนี้:

- GRU Layer ที่ 1:
  - มี 128 units
  - ใช้ฟังก์ชันการกระตุ้น tanh
  - return\_sequences=True เพื่อส่งคืนลำดับข้อมูลทั้งหมดไปยัง GRU Layer ถัดไป
- Dropout Layer ที่ 1:
  - ตั้ง rate=0.2 เพื่อลด overfitting
- GRU Layer ที่ 2:
  - มี 64 units
  - ใช้ฟังก์ชันการกระตุ้น tanh
  - return\_sequences=False เพื่อส่งคืนเฉพาะ hidden state สุดท้าย
- Dropout Layer ที่ 2:

- ตั้ง rate=0.2 เพื่อลด overfitting
5. Dense Layer ที่ 1:
    - มี 32 nodes
    - ใช้ฟังก์ชันการกระตุ้น relu
  6. Dense Layer สุดท้าย:
    - มี 1 node
    - ไม่มีฟังก์ชันการกระตุ้น (เหมาะสำหรับการทำนายค่าเชิงตัวเลข เช่น การพยากรณ์)
  7. Loss Function: ใช้ mean\_squared\_error (MSE) สำหรับวัดค่าความสูญเสีย
  8. Optimizer: ใช้ Adam ซึ่งปรับอัตราการเรียนรู้แบบอัตโนมัติ

ตารางที่ 4 แสดงค่า MAE, RMSE และ MAPE ของตัวแบบ GRU

Model	MAE	RMSE	MAPE
GRU	9.8327	11.0970	27.47 %

## การเปรียบเทียบประสิทธิภาพของตัวแบบในการพยากรณ์

จากตัวชี้วัดประสิทธิภาพการทำนายทั้งสามตัวแบบ เพื่อทำนายราคาชิ้นตำรายเดือนของถั่วเหลือง Okara ในประเทศเนปาล ได้ผลดังนี้

ตารางที่ 4 แสดงค่า MAE, RMSE และ MAPE ของตัวแบบอนุกรมเวลาทั้ง 3 ตัวแบบ

Model	MAE	RMSE	MAPE
SARIMA	11.34787	14.82118	39.39234%
ETS	10.4866	12.48023	29.2627%
GRU	9.8327	11.0970	27.47 %

จากการทำนายบน test set ของทั้ง 3 ตัวแบบอนุกรมเวลา พบว่า ตัวแบบ GRU เป็นตัวแบบที่ให้ผล MAE, RMSE และ MAPE น้อยที่สุด ดังนั้นตัวแบบ GRU จึงเป็นตัวแบบที่เหมาะสมที่สุดในการทำนายราคาชิ้นตำรายเดือนของถั่วเหลือง Okara ในประเทศเนปาล

## สรุปผล อภิปรายผล และข้อเสนอแนะ

### สรุปผล

จากข้อมูลราคาขั้นต่ำรายวันของถั่วเหลือง Okara ในประเทศเนปาลย้อนหลังตั้งแต่ปี พ.ศ.2013-2021 ที่ผ่านการวิเคราะห์สร้างตัวแบบอนุกรมเวลาไปจนถึงขั้นตอนการวัดประสิทธิภาพ สามารถสรุปผลออกมาได้ดังนี้

ตัวแบบทั้งสามที่ได้ศึกษา ประกอบด้วย SARIMA, Exponential Smoothing และ GRU(Gated Recurrent Unit) ทั้งสามโมเดล สามารถอธิบายราคาขั้นต่ำของถั่วเหลือง Okara ในประเทศเนปาล ได้โดยสรุปดังนี้

ตัวแบบ Gated Recurrent Unit เป็นตัวแบบที่มีประสิทธิภาพสูงที่สุด เนื่องจากให้ค่า MAE, RMSE และ MAPE ในการทำนายบน test set ต่ำที่สุด จึงสามารถสรุปได้ว่าตัวแบบ Gated Recurrent Unit เป็นตัวแบบที่มีประสิทธิภาพสูงที่สุดในการทำนายราคาขั้นต่ำรายวันของถั่วเหลือง Okara ในประเทศเนปาล

### อภิปรายผล

ผลลัพธ์ที่ได้ไม่เพียงช่วยสร้างความเข้าใจในความสัมพันธ์ของข้อมูลราคาในอดีต แต่ยังสามารถนำไปใช้เป็นเครื่องมือในการสนับสนุนการตัดสินใจทั้งในระดับบุคคลและระดับนโยบาย ซึ่งจะช่วยส่งเสริมความยั่งยืนในอุตสาหกรรมเกษตรกรรมของประเทศเนปาลในระยะยาว

### ข้อเสนอแนะ


เพื่อปรับปรุงความแม่นยำของการทำนายราคาถั่วเหลือง Okara ควรพิจารณาตัวแปรอื่นๆ (Explanatory Variables) ร่วมด้วย เช่น สภาพภูมิอากาศ (อุณหภูมิ, ปริมาณน้ำฝน), นโยบายรัฐบาลที่เกี่ยวข้องกับการเกษตร, หรือข้อมูลการค้าระหว่างประเทศ เพื่อให้ตัวแบบสามารถจับความสัมพันธ์ที่ซับซ้อนได้มากขึ้น

### รายการอ้างอิง


Ribeiro, S. M. (2022). *Imputation by decomposition and by time series nature: Novel imputation methods for missing data in time series* (Master's thesis, Universidade Federal de Minas Gerais). Retrieved from <https://github.com/silvanaribeiro/imputationLibrary>

ภาคผนวก

## EDA



ภาพที่ 1 แสดงถึงราคาขั้นต่ำ Okara ในช่วงปี 2013-2021




ภาพที่ 2 แสดงการแยกส่วนข้อมูลแบบ Additive โดยแสดงส่วนของ Trend, Seasonal และ Remainder

### Augmented Dickey-Fuller Test

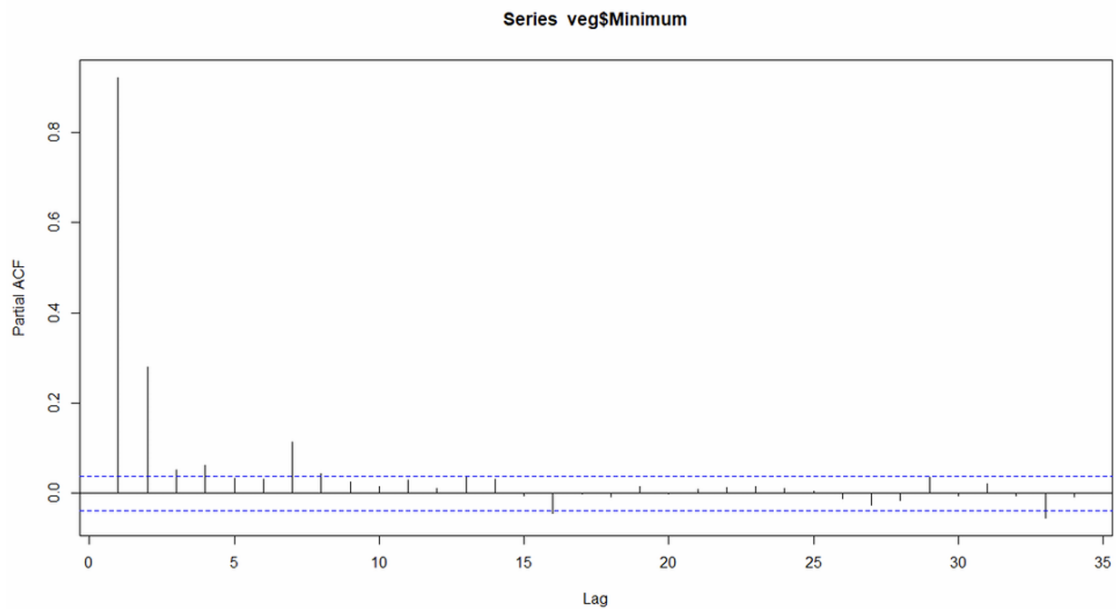
```
data: veg.ts  
Dickey-Fuller = -4.3999, Lag order = 13, p-value = 0.01  
alternative hypothesis: stationary
```

ภาพที่ 3 แสดงความเป็น stationary ของข้อมูลโดยค่า p-value ที่ได้จากการหา ADF Test มีค่า 0.01 ซึ่งมีค่าน้อยกว่า 0.05

## Auto correlation function



## Partial auto correlation function



ภาพที่ 4 และ 5 แสดงถึงกราฟ ACF (Auto-Correlation Function) และ PACF (Partial Auto-Correlation Function) เพื่อแสดงความสัมพันธ์ของข้อมูลในช่วง lag ต่าง ๆ

## Preprocessing

6	Okara	2013-06-21	45
7	Okara	2013-06-25	40
8	Okara	2013-06-26	35

37	Okara	2013-08-01	22
38	Okara	2013-08-02	26
39	Okara	2013-08-04	24



ภาพที่1 แสดงตารางสรุปจำนวนข้อมูลที่ขาดหายในแต่ละช่วงเวลา (Missing Data Report)

```
#Padding Missing Date  
veg_pad = pad(veg, interval = "day")  
veg_pad$Commodity = "Okara"
```

6	Okara	2013-06-21	45
7	Okara	2013-06-22	NA
8	Okara	2013-06-23	NA
9	Okara	2013-06-24	NA
10	Okara	2013-06-25	40

ภาพที่ 2 แสดงการใช้ฟังก์ชัน pad จาก library padr เพื่อเติมค่าวันที่ที่ขาดหาย





ภาพที่ 3 และ 4 แสดงการ พิจารณา Missing value ทั้หมด

```
#2. Splitting Training set And Test Set
#note : split point is October 14, 2019
train_set = veg_pad %>%
  filter(Date >= "2013-06-16", Date <= "2019-10-06")

test_set = veg_pad %>%
  filter(Date > "2019-10-06")
```

ภาพที่ 5 แสดงตารางสรุปช่วงเวลาที่ใช้สำหรับชุดข้อมูลฝึก (Training Set) และชุดข้อมูลทดสอบ (Testing Set)

```
impute_ts_kalman <- function(df){
  ts = ts(df[,3])
  ts_imputed = na_kalman(ts,model = "StructTS",smooth = TRUE)
  temp = df
  df_imputed = cbind(temp,data.frame(ts_imputed))
  df_imputed = df_imputed[,-3]
  names(df_imputed)[3] <- "Imputed_Minimum"
  return(df_imputed)
}
```

ภาพที่ 6 แสดงฟังก์ชันของการเติมค่าที่ขาดหายด้วยวิธีคาลมาน (Kalman Imputation)

```
> outliers = tsoutliers(ts(train_imputed$Imputed_Minimum))
> print(outliers)
$index
[1] 571 592

      Commodity      Date Imputed_Minimum
571      okara 2015-01-07             180
592      okara 2015-01-28             180
```

ภาพที่ 7 แสดงการตรวจหาค่าผิดปกติ (Outliers) ในชุดข้อมูลอนุกรมเวลาที่ผ่านมาการเติมค่าข้อมูลขาดหายแล้วซึ่งพบค่าผิดปกติ 2 จุดในชุดข้อมูล

```

temptrain = cbind(train_imputed,data.frame(train.ts))
temptrain = temptrain[,-3]
names(temptrain)[3] <- "Imputed_Minimum"

train_process = impute_ts_kalman(temptrain)

outlier_data = temptrain %>%
  filter(rowSums(is.na(.)) > 0)
trainjoin_df2 = inner_join(train_process, outlier_data, by = "Date")

```

ภาพที่ 8 แสดงการรวมกระบวนการเติมค่าข้อมูลขาดหายและการตรวจสอบค่าผิดปกติในชุดข้อมูลฝึก (Training Set)

	Commodity	Date	Imputed_Minimum
571	okara	2015-01-07	159.829
592	okara	2015-01-28	112.951

ภาพที่ 9 แสดงผลลัพธ์จากการเติมค่าที่หายไปด้วย วิธีKalman Imputation

## Model building - SARIMA

```
Error in makeARIMA(trarma[[1L]], trarma[[2L]], Delta, kappa, SSinit) :  
  maximum supported lag is 350
```

ภาพที่ 1 แสดง Error ที่เกิดขึ้นจากการที่ข้อมูลมี Seasonal เป็นแบบ daily ทำให้มี lag เกิน 350 lag

```
> print(adf_test)
```

Augmented Dickey-Fuller Test

```
data: train_ts  
Dickey-Fuller = -7.4374, Lag order = 4, p-value = 0.01  
alternative hypothesis: stationary
```


ภาพที่ 2 แสดงค่า p-value จาก ADF test สำหรับ train dataset

```
> print(kpss_test)
```

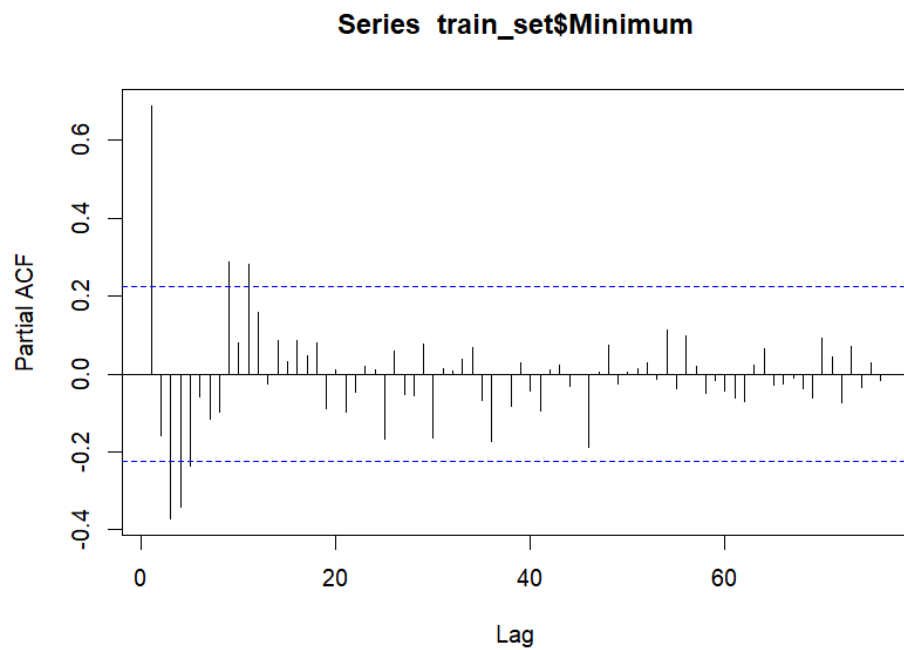
KPSS Test for Level Stationarity

```
data: train_ts  
KPSS Level = 0.18692, Truncation lag parameter = 3, p-value = 0.1
```


ภาพที่ 3 แสดงค่า p-value จาก KPSS test สำหรับ train dataset



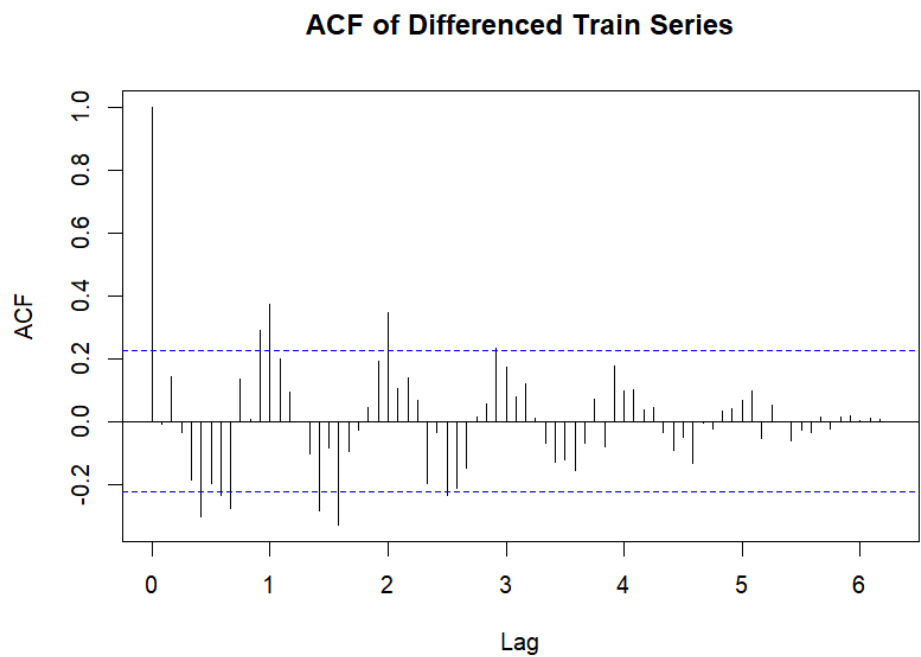
ภาพที่ 4 แสดงกราฟ ACF ของ train dataset แบบ monthly



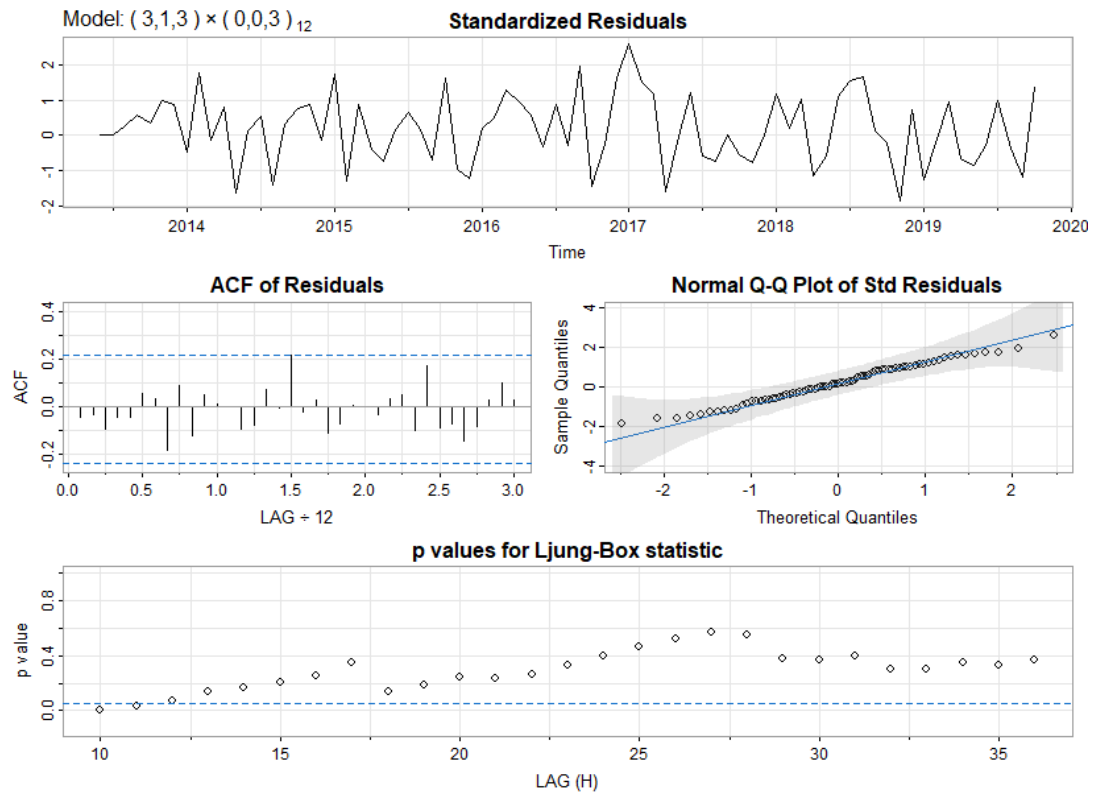
ภาพที่ 5 แสดงกราฟ PACF ของ train dataset แบบ monthly




ภาพที่ 6 แสดงกราฟ PACF หลังจากการทำ First-Order Differencing



ภาพที่ 7 แสดงกราฟ ACF หลังจากการทำ First-Order Differencing




ภาพที่ 8 แสดงภาพ plot graph ของค่า residual หลังจากการทำ SARIMA  $(3, 1, 3) \times (0, 0, 3)_{12}$



ภาพที่ 9 แสดงภาพ ผลลัพธ์จากการใช้ตัวแบบ SARIMA  $(3, 1, 3) \times (0, 0, 3)_{12}$  ในการทำนายข้อมูล

## Model building - ETS



ภาพที่ 1 แสดงการแยกส่วนข้อมูล โดยแสดงส่วนของ Trend, Seasonal และ Remainder ของ train dataset แบบ monthly



```
> manual_ets_model1 <- ets(train_ts, model = "MNM")
> summary(manual_ets_model1)
ETS(M,N,M)
```

Call:

```
ets(y = train_ts, model = "MNM")
```

Smoothing parameters:

```
alpha = 0.1236
gamma = 1e-04
```

Initial states:

```
l = 41.8242
s = 0.5367 0.9101 1.3699 1.4731 1.613 1.4103
    1.1749 1.0366 0.8058 0.5438 0.5995 0.5265
```

sigma: 0.2357

```
      AIC      AICc      BIC
692.3304 700.1992 727.4875
```

Training set error measures:

```
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 1.4392 8.469181 6.797757 -2.434829 18.28993 0.7426121 0.03551126
```

ภาพที่ 2 แสดงตัวแบบ ETS แบบ Multiplicative Error, No Trend, Multiplicative Seasonality

```
> manual_ets_model2 <- ets(train_ts, model = "MNA")
> summary(manual_ets_model2)
ETS(M,N,A)
```

Call:

```
ets(y = train_ts, model = "MNA")
```

Smoothing parameters:

```
alpha = 0.1175
gamma = 1e-04
```

Initial states:

```
l = 41.2693
s = -21.5742 -4.1784 19.7787 22.1622 27.0716 19.3636
    5.5029 1.1241 -6.8618 -21.6029 -18.2308 -22.555
```

sigma: 0.2296

```
      AIC      AICc      BIC
687.4437 695.3126 722.6008
```

Training set error measures:

```
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 1.066514 8.145093 6.449563 -1.448732 16.88829 0.7045741 -0.01568734
```

ภาพที่ 3 แสดง ตัวแบบ ETS แบบ Multiplicative Error, No Trend, Additive Seasonality

```

> manual_ets_model3 <- ets(train_ts, model = "ANA")
> summary(manual_ets_model3)
ETS(A,N,A)

Call:
ets(y = train_ts, model = "ANA")

Smoothing parameters:
  alpha = 0.1025
  gamma = 1e-04

Initial states:
  l = 41.8012
  s = -21.4335 -4.8328 19.8819 22.3653 27.3581 19.7522
      6.053 1.7354 -8.951 -22.1405 -17.7873 -22.0009

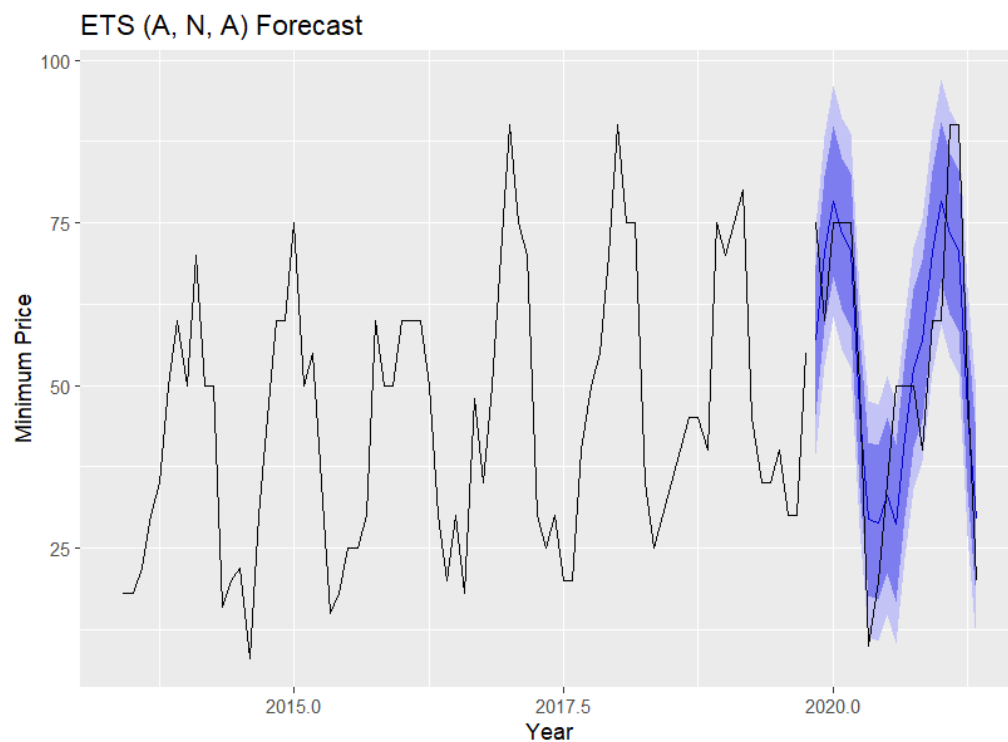
sigma: 8.9555

      AIC      AICc      BIC
686.6299 694.4987 721.7870

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 1.152021 8.100516 6.35306 -1.11949 16.49127 0.6940317 -0.006859548

```

ภาพที่ 4 แสดง ตัวแบบ ETS แบบ Additive Error, No Trend, Additive Seasonality



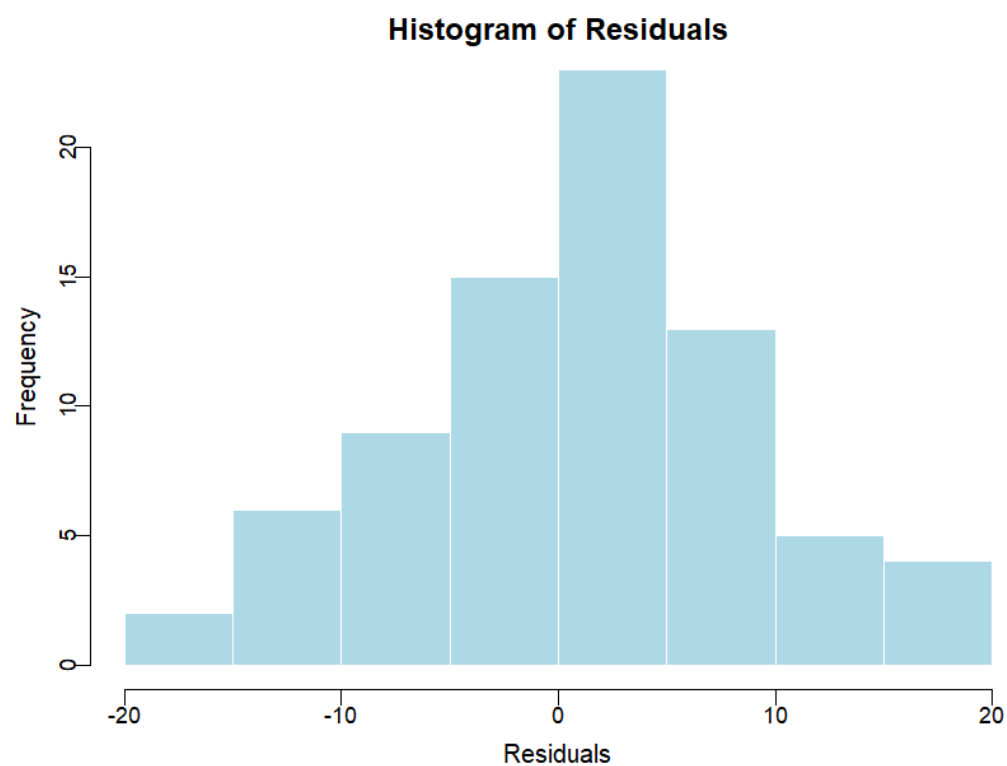
ภาพที่ 5 แสดงการ ทำนายของตัวแบบ ETS แบบ Additive Error, No Trend, Additive Seasonality

### Box-Ljung test


data: residuals\_ets3

X-squared = 22.931, df = 20, p-value = 0.2922

ภาพที่ 6 แสดงค่า p-value ของ Box – Ljung test ใน ตัวแบบ ETS(A, N, A)



ภาพที่ 7 แสดงกราฟ Histogram ของ residual ในตัวแบบ ETS(A, N, A)



ภาพที่ 8 แสดงกราฟ ACF ของ residual ในตัวแบบ ETS(A, N, A)

## Model building -GRU

```
Epoch 1/150
<ipython-input-62-4c11d222ce9c>:28: FutureWarning: Series.fillna with 'method' is
deprecated and will raise in a future version. Use obj.ffill() or obj.bfill()
instead.
test_df['Lag1'] = test_df['Minimum'].shift(1).fillna(method='bfill')
<ipython-input-62-4c11d222ce9c>:32: FutureWarning: Series.fillna with 'method' is
deprecated and will raise in a future version. Use obj.ffill() or obj.bfill()
instead.
test_df['MovingAvg3'] =
test_df['Minimum'].rolling(window=3).mean().fillna(method='bfill')
/usr/local/lib/python3.10/dist-packages/keras/src/layers/rnn/rnn.py:204:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first layer
in the model instead.
super().__init__(**kwargs)
4/4 ━━━━━━━━━━━━━━━━━ 6s 279ms/step - loss: 0.1986 - mae: 0.3824 - val_loss:
0.1552 - val_mae: 0.3422
Epoch 2/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 18ms/step - loss: 0.1296 - mae: 0.2894 - val_loss:
0.0666 - val_mae: 0.1886
Epoch 3/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 15ms/step - loss: 0.0505 - mae: 0.1704 - val_loss:
0.0297 - val_mae: 0.1530
Epoch 4/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 15ms/step - loss: 0.0478 - mae: 0.1833 - val_loss:
0.0503 - val_mae: 0.1984
Epoch 5/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 15ms/step - loss: 0.0516 - mae: 0.1791 - val_loss:
0.0448 - val_mae: 0.1844
Epoch 6/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 15ms/step - loss: 0.0437 - mae: 0.1704 - val_loss:
0.0266 - val_mae: 0.1496
Epoch 7/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 15ms/step - loss: 0.0299 - mae: 0.1355 - val_loss:
0.0233 - val_mae: 0.1267
Epoch 8/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 19ms/step - loss: 0.0352 - mae: 0.1563 - val_loss:
0.0243 - val_mae: 0.1248
Epoch 9/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 16ms/step - loss: 0.0283 - mae: 0.1396 - val_loss:
0.0236 - val_mae: 0.1231
Epoch 10/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 17ms/step - loss: 0.0298 - mae: 0.1379 - val_loss:
0.0215 - val_mae: 0.1165
Epoch 11/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 17ms/step - loss: 0.0216 - mae: 0.1208 - val_loss:
0.0208 - val_mae: 0.1146
Epoch 12/150
4/4 ━━━━━━━━━━━━━━━━━ 0s 16ms/step - loss: 0.0245 - mae: 0.1268 - val_loss:
```

0.0212 - val\_mae: 0.1148  
Epoch 13/150  
4/4 \_\_\_\_\_ 0s 14ms/step - loss: 0.0224 - mae: 0.1143 - val\_loss:  
0.0201 - val\_mae: 0.1109  
Epoch 14/150  
4/4 \_\_\_\_\_ 0s 17ms/step - loss: 0.0236 - mae: 0.1270 - val\_loss:  
0.0196 - val\_mae: 0.1106  
Epoch 15/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0254 - mae: 0.1301 - val\_loss:  
0.0202 - val\_mae: 0.1137  
Epoch 16/150  
4/4 \_\_\_\_\_ 0s 20ms/step - loss: 0.0240 - mae: 0.1254 - val\_loss:  
0.0203 - val\_mae: 0.1144  
Epoch 17/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0249 - mae: 0.1262 - val\_loss:  
0.0198 - val\_mae: 0.1133  
Epoch 18/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0223 - mae: 0.1216 - val\_loss:  
0.0188 - val\_mae: 0.1108  
Epoch 19/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0261 - mae: 0.1268 - val\_loss:  
0.0183 - val\_mae: 0.1092  
Epoch 20/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0180 - mae: 0.1005 - val\_loss:  
0.0190 - val\_mae: 0.1103  
Epoch 21/150  
4/4 \_\_\_\_\_ 0s 26ms/step - loss: 0.0215 - mae: 0.1121 - val\_loss:  
0.0197 - val\_mae: 0.1130  
Epoch 22/150  
4/4 \_\_\_\_\_ 0s 23ms/step - loss: 0.0222 - mae: 0.1163 - val\_loss:  
0.0202 - val\_mae: 0.1147  
Epoch 23/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0246 - mae: 0.1273 - val\_loss:  
0.0184 - val\_mae: 0.1088  
Epoch 24/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0215 - mae: 0.1172 - val\_loss:  
0.0184 - val\_mae: 0.1095  
Epoch 25/150  
4/4 \_\_\_\_\_ 0s 21ms/step - loss: 0.0215 - mae: 0.1096 - val\_loss:  
0.0197 - val\_mae: 0.1146  
Epoch 26/150  
4/4 \_\_\_\_\_ 0s 17ms/step - loss: 0.0219 - mae: 0.1188 - val\_loss:  
0.0213 - val\_mae: 0.1190  
Epoch 27/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0176 - mae: 0.1081 - val\_loss:  
0.0217 - val\_mae: 0.1202  
Epoch 28/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0263 - mae: 0.1256 - val\_loss:  
0.0180 - val\_mae: 0.1098  
Epoch 29/150  
4/4 \_\_\_\_\_ 0s 17ms/step - loss: 0.0203 - mae: 0.1089 - val\_loss:  
0.0166 - val\_mae: 0.1049

Epoch 30/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0222 - mae: 0.1145 - val\_loss: 0.0167 - val\_mae: 0.1061  
Epoch 31/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0171 - mae: 0.1056 - val\_loss: 0.0182 - val\_mae: 0.1115  
Epoch 32/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0185 - mae: 0.1098 - val\_loss: 0.0195 - val\_mae: 0.1153  
Epoch 33/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0235 - mae: 0.1209 - val\_loss: 0.0176 - val\_mae: 0.1102  
Epoch 34/150  
4/4 \_\_\_\_\_ 0s 19ms/step - loss: 0.0197 - mae: 0.1080 - val\_loss: 0.0180 - val\_mae: 0.1113  
Epoch 35/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0170 - mae: 0.1043 - val\_loss: 0.0167 - val\_mae: 0.1073  
Epoch 36/150  
4/4 \_\_\_\_\_ 0s 22ms/step - loss: 0.0201 - mae: 0.1164 - val\_loss: 0.0156 - val\_mae: 0.1040  
Epoch 37/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0206 - mae: 0.1167 - val\_loss: 0.0162 - val\_mae: 0.1058  
Epoch 38/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0225 - mae: 0.1173 - val\_loss: 0.0156 - val\_mae: 0.1047  
Epoch 39/150  
4/4 \_\_\_\_\_ 0s 20ms/step - loss: 0.0215 - mae: 0.1123 - val\_loss: 0.0153 - val\_mae: 0.1043  
Epoch 40/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0204 - mae: 0.1190 - val\_loss: 0.0181 - val\_mae: 0.1129  
Epoch 41/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0174 - mae: 0.1018 - val\_loss: 0.0155 - val\_mae: 0.1049  
Epoch 42/150  
4/4 \_\_\_\_\_ 0s 28ms/step - loss: 0.0197 - mae: 0.1148 - val\_loss: 0.0139 - val\_mae: 0.0977  
Epoch 43/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0192 - mae: 0.1107 - val\_loss: 0.0149 - val\_mae: 0.1030  
Epoch 44/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0162 - mae: 0.0962 - val\_loss: 0.0152 - val\_mae: 0.1046  
Epoch 45/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0146 - mae: 0.1020 - val\_loss: 0.0136 - val\_mae: 0.0991  
Epoch 46/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0164 - mae: 0.1006 - val\_loss: 0.0142 - val\_mae: 0.1022  
Epoch 47/150

4/4 ————— 0s 15ms/step - loss: 0.0159 - mae: 0.0990 - val\_loss: 0.0140 - val\_mae: 0.0998  
Epoch 48/150

4/4 ————— 0s 16ms/step - loss: 0.0161 - mae: 0.0969 - val\_loss: 0.0141 - val\_mae: 0.0992  
Epoch 49/150

4/4 ————— 0s 16ms/step - loss: 0.0154 - mae: 0.0995 - val\_loss: 0.0145 - val\_mae: 0.1010  
Epoch 50/150

4/4 ————— 0s 25ms/step - loss: 0.0129 - mae: 0.0893 - val\_loss: 0.0139 - val\_mae: 0.0995  
Epoch 51/150

4/4 ————— 0s 17ms/step - loss: 0.0197 - mae: 0.1085 - val\_loss: 0.0130 - val\_mae: 0.0952  
Epoch 52/150

4/4 ————— 0s 15ms/step - loss: 0.0125 - mae: 0.0883 - val\_loss: 0.0125 - val\_mae: 0.0944  
Epoch 53/150

4/4 ————— 0s 21ms/step - loss: 0.0151 - mae: 0.0974 - val\_loss: 0.0155 - val\_mae: 0.1059  
Epoch 54/150

4/4 ————— 0s 16ms/step - loss: 0.0158 - mae: 0.0957 - val\_loss: 0.0128 - val\_mae: 0.0977  
Epoch 55/150

4/4 ————— 0s 16ms/step - loss: 0.0160 - mae: 0.1023 - val\_loss: 0.0116 - val\_mae: 0.0929  
Epoch 56/150

4/4 ————— 0s 16ms/step - loss: 0.0184 - mae: 0.1065 - val\_loss: 0.0130 - val\_mae: 0.0967  
Epoch 57/150

4/4 ————— 0s 17ms/step - loss: 0.0154 - mae: 0.0995 - val\_loss: 0.0117 - val\_mae: 0.0916  
Epoch 58/150

4/4 ————— 0s 16ms/step - loss: 0.0162 - mae: 0.0984 - val\_loss: 0.0131 - val\_mae: 0.0978  
Epoch 59/150

4/4 ————— 0s 22ms/step - loss: 0.0138 - mae: 0.0864 - val\_loss: 0.0125 - val\_mae: 0.0951  
Epoch 60/150

4/4 ————— 0s 26ms/step - loss: 0.0155 - mae: 0.0981 - val\_loss: 0.0138 - val\_mae: 0.1009  
Epoch 61/150

4/4 ————— 0s 16ms/step - loss: 0.0124 - mae: 0.0877 - val\_loss: 0.0113 - val\_mae: 0.0934  
Epoch 62/150

4/4 ————— 0s 16ms/step - loss: 0.0133 - mae: 0.0944 - val\_loss: 0.0106 - val\_mae: 0.0913  
Epoch 63/150

4/4 ————— 0s 18ms/step - loss: 0.0137 - mae: 0.0951 - val\_loss: 0.0114 - val\_mae: 0.0931  
Epoch 64/150

4/4 ————— 0s 15ms/step - loss: 0.0126 - mae: 0.0923 - val\_loss:



0.0119 - val\_mae: 0.0945  
Epoch 65/150  
4/4 \_\_\_\_\_ 0s 25ms/step - loss: 0.0118 - mae: 0.0838 - val\_loss:  
0.0131 - val\_mae: 0.0989  
Epoch 66/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0151 - mae: 0.0980 - val\_loss:  
0.0120 - val\_mae: 0.0949  
Epoch 67/150  
4/4 \_\_\_\_\_ 0s 25ms/step - loss: 0.0119 - mae: 0.0869 - val\_loss:  
0.0115 - val\_mae: 0.0929  
Epoch 68/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0099 - mae: 0.0775 - val\_loss:  
0.0113 - val\_mae: 0.0920  
Epoch 69/150  
4/4 \_\_\_\_\_ 0s 18ms/step - loss: 0.0109 - mae: 0.0885 - val\_loss:  
0.0129 - val\_mae: 0.0965  
Epoch 70/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0149 - mae: 0.0966 - val\_loss:  
0.0098 - val\_mae: 0.0873  
Epoch 71/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0099 - mae: 0.0807 - val\_loss:  
0.0095 - val\_mae: 0.0866  
Epoch 72/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0111 - mae: 0.0847 - val\_loss:  
0.0106 - val\_mae: 0.0893  
Epoch 73/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0114 - mae: 0.0850 - val\_loss:  
0.0110 - val\_mae: 0.0910  
Epoch 74/150  
4/4 \_\_\_\_\_ 0s 19ms/step - loss: 0.0112 - mae: 0.0874 - val\_loss:  
0.0086 - val\_mae: 0.0810  
Epoch 75/150  
4/4 \_\_\_\_\_ 0s 17ms/step - loss: 0.0088 - mae: 0.0752 - val\_loss:  
0.0086 - val\_mae: 0.0810  
Epoch 76/150  
4/4 \_\_\_\_\_ 0s 24ms/step - loss: 0.0137 - mae: 0.0862 - val\_loss:  
0.0122 - val\_mae: 0.0929  
Epoch 77/150  
4/4 \_\_\_\_\_ 0s 18ms/step - loss: 0.0117 - mae: 0.0872 - val\_loss:  
0.0106 - val\_mae: 0.0887  
Epoch 78/150  
4/4 \_\_\_\_\_ 0s 18ms/step - loss: 0.0112 - mae: 0.0834 - val\_loss:  
0.0075 - val\_mae: 0.0777  
Epoch 79/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0113 - mae: 0.0847 - val\_loss:  
0.0075 - val\_mae: 0.0783  
Epoch 80/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0113 - mae: 0.0867 - val\_loss:  
0.0103 - val\_mae: 0.0875  
Epoch 81/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0103 - mae: 0.0850 - val\_loss:  
0.0091 - val\_mae: 0.0842

Epoch 82/150  
4/4 \_\_\_\_\_ 0s 24ms/step - loss: 0.0105 - mae: 0.0844 - val\_loss: 0.0071 - val\_mae: 0.0746  
Epoch 83/150  
4/4 \_\_\_\_\_ 0s 18ms/step - loss: 0.0076 - mae: 0.0669 - val\_loss: 0.0074 - val\_mae: 0.0771  
Epoch 84/150  
4/4 \_\_\_\_\_ 0s 19ms/step - loss: 0.0105 - mae: 0.0804 - val\_loss: 0.0084 - val\_mae: 0.0804  
Epoch 85/150  
4/4 \_\_\_\_\_ 0s 36ms/step - loss: 0.0065 - mae: 0.0624 - val\_loss: 0.0078 - val\_mae: 0.0788  
Epoch 86/150  
4/4 \_\_\_\_\_ 0s 25ms/step - loss: 0.0077 - mae: 0.0730 - val\_loss: 0.0083 - val\_mae: 0.0799  
Epoch 87/150  
4/4 \_\_\_\_\_ 0s 30ms/step - loss: 0.0065 - mae: 0.0651 - val\_loss: 0.0089 - val\_mae: 0.0817  
Epoch 88/150  
4/4 \_\_\_\_\_ 0s 21ms/step - loss: 0.0080 - mae: 0.0756 - val\_loss: 0.0072 - val\_mae: 0.0758  
Epoch 89/150  
4/4 \_\_\_\_\_ 0s 25ms/step - loss: 0.0067 - mae: 0.0667 - val\_loss: 0.0070 - val\_mae: 0.0741  
Epoch 90/150  
4/4 \_\_\_\_\_ 0s 30ms/step - loss: 0.0073 - mae: 0.0696 - val\_loss: 0.0084 - val\_mae: 0.0788  
Epoch 91/150  
4/4 \_\_\_\_\_ 0s 20ms/step - loss: 0.0091 - mae: 0.0750 - val\_loss: 0.0073 - val\_mae: 0.0720  
Epoch 92/150  
4/4 \_\_\_\_\_ 0s 23ms/step - loss: 0.0066 - mae: 0.0649 - val\_loss: 0.0067 - val\_mae: 0.0719  
Epoch 93/150  
4/4 \_\_\_\_\_ 0s 22ms/step - loss: 0.0077 - mae: 0.0716 - val\_loss: 0.0075 - val\_mae: 0.0755  
Epoch 94/150  
4/4 \_\_\_\_\_ 0s 32ms/step - loss: 0.0081 - mae: 0.0721 - val\_loss: 0.0085 - val\_mae: 0.0790  
Epoch 95/150  
4/4 \_\_\_\_\_ 0s 28ms/step - loss: 0.0093 - mae: 0.0741 - val\_loss: 0.0072 - val\_mae: 0.0736  
Epoch 96/150  
4/4 \_\_\_\_\_ 0s 25ms/step - loss: 0.0075 - mae: 0.0708 - val\_loss: 0.0077 - val\_mae: 0.0747  
Epoch 97/150  
4/4 \_\_\_\_\_ 0s 39ms/step - loss: 0.0087 - mae: 0.0714 - val\_loss: 0.0098 - val\_mae: 0.0829  
Epoch 98/150  
4/4 \_\_\_\_\_ 0s 26ms/step - loss: 0.0105 - mae: 0.0835 - val\_loss: 0.0077 - val\_mae: 0.0749  
Epoch 99/150

4/4 \_\_\_\_\_ 0s 29ms/step - loss: 0.0058 - mae: 0.0603 - val\_loss:  
0.0065 - val\_mae: 0.0734  
Epoch 100/150

4/4 \_\_\_\_\_ 0s 29ms/step - loss: 0.0092 - mae: 0.0731 - val\_loss:  
0.0076 - val\_mae: 0.0737  
Epoch 101/150

4/4 \_\_\_\_\_ 0s 30ms/step - loss: 0.0091 - mae: 0.0773 - val\_loss:  
0.0090 - val\_mae: 0.0761  
Epoch 102/150

4/4 \_\_\_\_\_ 0s 24ms/step - loss: 0.0073 - mae: 0.0709 - val\_loss:  
0.0070 - val\_mae: 0.0708  
Epoch 103/150

4/4 \_\_\_\_\_ 0s 30ms/step - loss: 0.0072 - mae: 0.0671 - val\_loss:  
0.0079 - val\_mae: 0.0755  
Epoch 104/150

4/4 \_\_\_\_\_ 0s 36ms/step - loss: 0.0063 - mae: 0.0608 - val\_loss:  
0.0077 - val\_mae: 0.0750  
Epoch 105/150

4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0064 - mae: 0.0653 - val\_loss:  
0.0066 - val\_mae: 0.0704  
Epoch 106/150

4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0061 - mae: 0.0629 - val\_loss:  
0.0070 - val\_mae: 0.0702  
Epoch 107/150

4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0077 - mae: 0.0693 - val\_loss:  
0.0079 - val\_mae: 0.0760  
Epoch 108/150

4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0094 - mae: 0.0772 - val\_loss:  
0.0070 - val\_mae: 0.0683  
Epoch 109/150

4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0079 - mae: 0.0767 - val\_loss:  
0.0075 - val\_mae: 0.0680  
Epoch 110/150

4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0075 - mae: 0.0682 - val\_loss:  
0.0092 - val\_mae: 0.0815  
Epoch 111/150

4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0086 - mae: 0.0769 - val\_loss:  
0.0071 - val\_mae: 0.0711  
Epoch 112/150

4/4 \_\_\_\_\_ 0s 21ms/step - loss: 0.0074 - mae: 0.0708 - val\_loss:  
0.0072 - val\_mae: 0.0673  
Epoch 113/150

4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0065 - mae: 0.0685 - val\_loss:  
0.0085 - val\_mae: 0.0679  
Epoch 114/150

4/4 \_\_\_\_\_ 0s 17ms/step - loss: 0.0088 - mae: 0.0761 - val\_loss:  
0.0082 - val\_mae: 0.0766  
Epoch 115/150

4/4 \_\_\_\_\_ 0s 17ms/step - loss: 0.0090 - mae: 0.0784 - val\_loss:  
0.0077 - val\_mae: 0.0739  
Epoch 116/150

4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0080 - mae: 0.0685 - val\_loss:

0.0062 - val\_mae: 0.0700  
Epoch 117/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0072 - mae: 0.0673 - val\_loss:  
0.0076 - val\_mae: 0.0667  
Epoch 118/150  
4/4 \_\_\_\_\_ 0s 17ms/step - loss: 0.0062 - mae: 0.0674 - val\_loss:  
0.0104 - val\_mae: 0.0870  
Epoch 119/150  
4/4 \_\_\_\_\_ 0s 17ms/step - loss: 0.0076 - mae: 0.0704 - val\_loss:  
0.0081 - val\_mae: 0.0745  
Epoch 120/150  
4/4 \_\_\_\_\_ 0s 19ms/step - loss: 0.0109 - mae: 0.0833 - val\_loss:  
0.0077 - val\_mae: 0.0679  
Epoch 121/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0075 - mae: 0.0719 - val\_loss:  
0.0080 - val\_mae: 0.0665  
Epoch 122/150  
4/4 \_\_\_\_\_ 0s 21ms/step - loss: 0.0083 - mae: 0.0759 - val\_loss:  
0.0090 - val\_mae: 0.0797  
Epoch 123/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0087 - mae: 0.0686 - val\_loss:  
0.0080 - val\_mae: 0.0734  
Epoch 124/150  
4/4 \_\_\_\_\_ 0s 18ms/step - loss: 0.0081 - mae: 0.0732 - val\_loss:  
0.0075 - val\_mae: 0.0671  
Epoch 125/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0080 - mae: 0.0699 - val\_loss:  
0.0081 - val\_mae: 0.0673  
Epoch 126/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0071 - mae: 0.0697 - val\_loss:  
0.0071 - val\_mae: 0.0686  
Epoch 127/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0067 - mae: 0.0638 - val\_loss:  
0.0074 - val\_mae: 0.0716  
Epoch 128/150  
4/4 \_\_\_\_\_ 0s 26ms/step - loss: 0.0081 - mae: 0.0651 - val\_loss:  
0.0078 - val\_mae: 0.0690  
Epoch 129/150  
4/4 \_\_\_\_\_ 0s 18ms/step - loss: 0.0084 - mae: 0.0712 - val\_loss:  
0.0070 - val\_mae: 0.0674  
Epoch 130/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0066 - mae: 0.0650 - val\_loss:  
0.0068 - val\_mae: 0.0675  
Epoch 131/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0079 - mae: 0.0726 - val\_loss:  
0.0074 - val\_mae: 0.0694  
Epoch 132/150  
4/4 \_\_\_\_\_ 0s 15ms/step - loss: 0.0064 - mae: 0.0658 - val\_loss:  
0.0091 - val\_mae: 0.0762  
Epoch 133/150  
4/4 \_\_\_\_\_ 0s 16ms/step - loss: 0.0065 - mae: 0.0696 - val\_loss:  
0.0071 - val\_mae: 0.0668

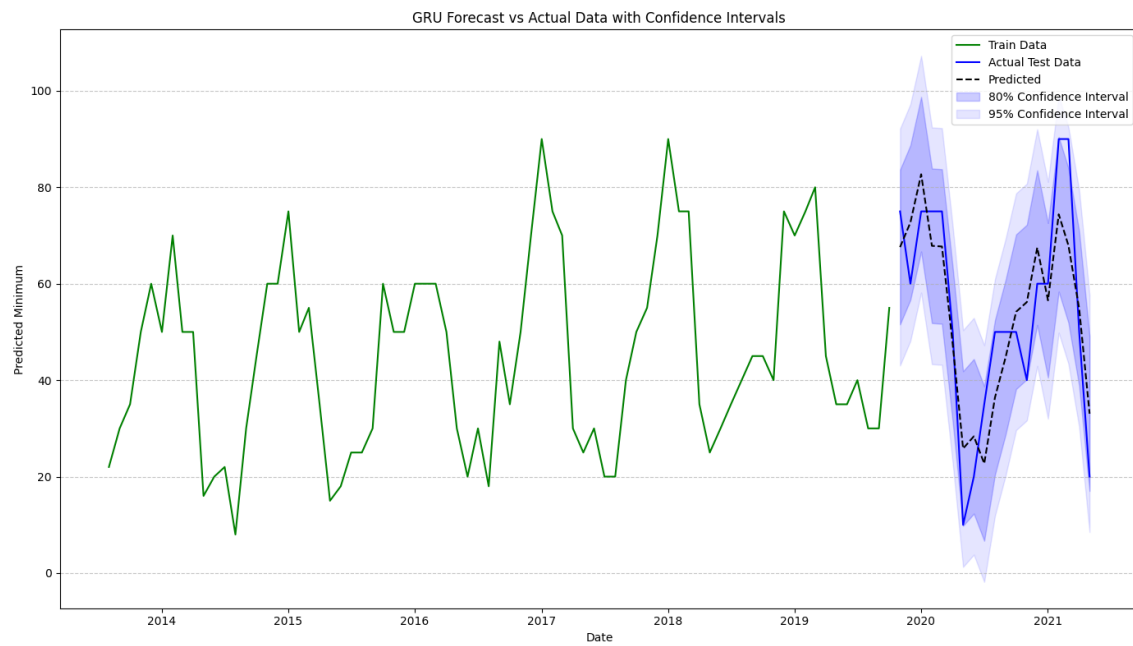
Epoch 134/150  
4/4 ————— 0s 20ms/step - loss: 0.0075 - mae: 0.0688 - val\_loss: 0.0070 - val\_mae: 0.0663  
Epoch 135/150  
4/4 ————— 0s 26ms/step - loss: 0.0120 - mae: 0.0881 - val\_loss: 0.0071 - val\_mae: 0.0658  
Epoch 136/150  
4/4 ————— 0s 18ms/step - loss: 0.0047 - mae: 0.0564 - val\_loss: 0.0078 - val\_mae: 0.0655  
Epoch 137/150  
4/4 ————— 0s 17ms/step - loss: 0.0070 - mae: 0.0692 - val\_loss: 0.0081 - val\_mae: 0.0704  
Epoch 138/150  
4/4 ————— 0s 18ms/step - loss: 0.0074 - mae: 0.0683 - val\_loss: 0.0092 - val\_mae: 0.0769  
Epoch 139/150  
4/4 ————— 0s 16ms/step - loss: 0.0070 - mae: 0.0689 - val\_loss: 0.0069 - val\_mae: 0.0662  
Epoch 140/150  
4/4 ————— 0s 15ms/step - loss: 0.0056 - mae: 0.0600 - val\_loss: 0.0060 - val\_mae: 0.0689  
Epoch 141/150  
4/4 ————— 0s 17ms/step - loss: 0.0059 - mae: 0.0662 - val\_loss: 0.0071 - val\_mae: 0.0657  
Epoch 142/150  
4/4 ————— 0s 16ms/step - loss: 0.0047 - mae: 0.0599 - val\_loss: 0.0101 - val\_mae: 0.0786  
Epoch 143/150  
4/4 ————— 0s 19ms/step - loss: 0.0088 - mae: 0.0731 - val\_loss: 0.0074 - val\_mae: 0.0700  
Epoch 144/150  
4/4 ————— 0s 31ms/step - loss: 0.0061 - mae: 0.0658 - val\_loss: 0.0071 - val\_mae: 0.0701  
Epoch 145/150  
4/4 ————— 0s 16ms/step - loss: 0.0081 - mae: 0.0709 - val\_loss: 0.0065 - val\_mae: 0.0684  
Epoch 146/150  
4/4 ————— 0s 16ms/step - loss: 0.0060 - mae: 0.0625 - val\_loss: 0.0086 - val\_mae: 0.0734  
Epoch 147/150  
4/4 ————— 0s 17ms/step - loss: 0.0059 - mae: 0.0624 - val\_loss: 0.0114 - val\_mae: 0.0816  
Epoch 148/150  
4/4 ————— 0s 18ms/step - loss: 0.0080 - mae: 0.0692 - val\_loss: 0.0075 - val\_mae: 0.0670  
Epoch 149/150  
4/4 ————— 0s 15ms/step - loss: 0.0074 - mae: 0.0690 - val\_loss: 0.0063 - val\_mae: 0.0705  
Epoch 150/150  
4/4 ————— 0s 16ms/step - loss: 0.0065 - mae: 0.0653 - val\_loss: 0.0069 - val\_mae: 0.0689  
1/1 ————— 0s 28ms/step - loss: 0.0183 - mae: 0.1199

Test Loss: 0.01831411011517048

Test MAE: 0.11991134285926819

1/1 ————— 0s 400ms/step

ภาพที่ 1 แสดงผลลัพธ์การ Run ของตัวแบบ GRU



ภาพที่ 2 แสดงผลลัพธ์จากการทำนายโดยตัวแบบ GRU